- Tous les documents sont autorisés.
- Durée : **2h.**
- Ce sujet comporte **12 pages** et **29 questions**, pour un total de **38 points**.
- Répondez **succinctement**.
- Rendez les deux parties sur **deux copies différentes** et **numérotez** les questions.

Partie 1

À rendre sur une copie différente de la partie 2.

Exercice 1 : Du thon au mercure

Une association de protection des océans décide de mener une enquête sur la contamination au mercure du thon en boîte. Pour cela, elle collecte $n = 200$ boîtes de thon de plusieurs marques dans divers supermarchés et en fait analyser les compositions par un laboratoire indépendant. A l'issue de ce processus, l'association dispose d'un échantillon $(x_1, \ldots, x_n)$ de concentrations en mercure, exprimées en mg/kg, dont les principales caractéristiques sont représentées en figure 1 (les données utilisées dans cet examen sont fictives, obtenues par simulation).

Écart-type	0,690
Moyenne	0,619
Minimum	0,001
1er quartile	0,113
Médiane	0,377
3ème quartile	0,831
Maximum	3,509

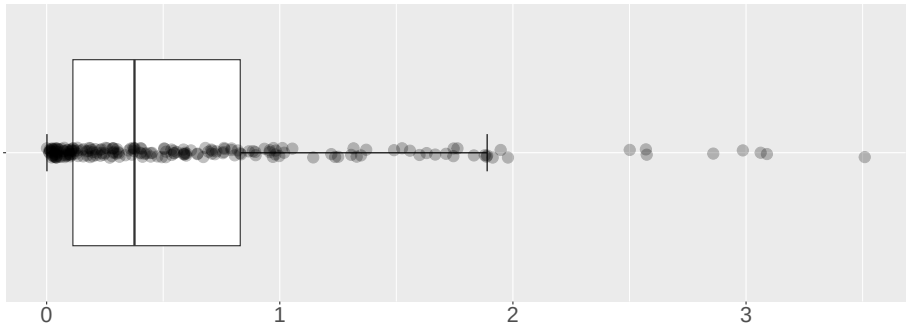


FIGURE 1 – Indicateurs numériques et boîte à moustache de la série statistique $(x_1, \ldots, x_n)$.

1. (2 points) Décrire la variable observée sur l'échantillon et son comportement à l'aide de la figure 1. Pensez-vous qu'il soit pertinent de modéliser cette variable à l'aide d'une loi Normale ? D'une loi de Poisson ? Justifiez vos réponses. (1-5 lignes)

Solution : La concentration en mercure dans une boîte de thon est une variable quantitative continue, à valeurs toujours positives. Sa distribution semble très fortement asymétrique, avec des grandes valeurs assez fréquentes. Ni une loi Normale, symétrique, ni une loi de Poisson, discrète et dont l'espérance coïncide avec la variance, ne seraient appropriées pour la modéliser.

***cf.* poly :** §1.3.1 §2.1

On cherche à évaluer la probabilité p_s que la concentration de mercure dans une boîte de thon prise au hasard dans un supermarché quelconque dépasse un seuil de sécurité $s > 0$, potentiellement grand.

Pour cela, on suppose dorénavant que l'échantillon observé est une réalisation d'un échantillon aléatoire $(X_1, \ldots, X_n)$ dont les n composantes sont des variables aléatoires indépendantes, de même loi $\mathbb{P}_X$ qu'une variable générique X.

2. (1 point) Explicitez le modèle statistique suggéré ci-dessus.

Solution : Le modèle statistique est défini par les trois points suivants :

- l'espace dans lequel l'échantillon aléatoire prend ses valeurs : $\mathbb{R}_+^n$,
- la tribu associée : celle des boréliens de $\mathbb{R}_+^n$,
- la loi du vecteur $(X_1, \ldots, X_n)$: $\mathbb{P}_X^{\otimes n}$.

***cf.* poly :** §3.1.2

On commence par proposer d'estimer p_s à l'aide de la moyenne empirique des indicatrices que les observations dépassent le seuil s :

$$\hat{p}_s = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}_{[s,+\infty[}(x_i).$$

3. (2 points) Donner le biais et la variance de l'estimateur $\hat{P}_s$ correspondant. Est-il convergent ?

Solution : On a $\hat{P}_s = \dfrac{1}{n} \displaystyle\sum_{i=1}^{n} \mathbf{1}_{[s,+\infty[}(X_i)$, fonction de l'échantillon *aléatoire*.

Il s'agit de la moyenne de n variables de Bernoulli indépendantes de même paramètre p_s. Ainsi,

$$\mathbb{E}(\hat{P}_s) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{E}\left(\mathbf{1}_{[s,+\infty[}(X_i)\right) \overset{\text{(iid)}}{=} p_s, \quad \text{d'où} \quad B(\hat{P}_s) = \mathbb{E}(\hat{P}_s) - p_s = 0.$$

Par ailleurs,

$$\mathbb{V}(\hat{P}_s) \overset{\text{(iid)}}{=} \frac{1}{n^2} \sum_{i=1}^{n} \mathbb{V}\left(\mathbf{1}_{[s,+\infty[}(X)\right) = \frac{1}{n} p_s(1 - p_s).$$

Cet estimateur est sans biais et sa variance tend vers 0 quand $n \to +\infty$, il est donc bien convergent, et même fortement convergent d'après la loi des grands nombres.

***cf.* poly :** §3.2.1 §3.3.1 §3.3.4

4. (1 point) Donner l'estimation de $p_{3,51}$.

Solution : Comme le maximum de l'échantillon est $3{,}509$ (*cf.* figure 1) on a $\hat{p}_{3,51} = 0$.

***cf.* poly :** §3.2.1

5. (1 point) À quelle condition l'estimateur $\hat{P}_s$ nous permet-il d'estimer une probabilité inférieure à $0{,}001$ de dépasser un seuil s très grand ?

Solution : Pour espérer pouvoir estimer une probabilité inférieure à $0{,}001$ de dépasser un seuil s très grand avec $\hat{P}_s$, il faudrait disposer de plus de 1000 observations.

***cf.* poly :** §3.2 §3.3

6. (1 point) Proposer une manière d'estimer une probabilité $p_s < \dfrac{1}{n}$ de dépasser un seuil s très grand.

Solution : Par construction, $\hat{P}_s$ ne peut estimer autrement que par 0 une probabilité $p_s < \dfrac{1}{n}$.

Il faut donc changer de méthode d'estimation : on peut proposer une forme paramétrique $\mathbb{P}_\theta$ pour $\mathbb{P}_X$, avec un petit nombre d de paramètres $\theta \in \mathbb{R}^d$, puis les estimer (par exemple par maximum de vraisemblance). A partir de l'estimation $\hat{\theta}$, on peut alors déduire $\hat{p}_s = \mathbb{P}_{\hat{\theta}}([s, +\infty[\,)$.

***cf.* poly :** §3.1.2 §3.5

On suppose dorénavant que $\mathbb{P}_X$ est une loi de Pareto de paramètres $\alpha, u > 0$, de fonction de répartition

$$\forall\, x \in \mathbb{R} \qquad F_{\alpha,u}(x) = \left(1 - \left(\frac{u}{x}\right)^{\alpha}\right) \mathbf{1}_{[u,+\infty[}(x).$$

7. (3 points) Donner la vraisemblance puis la log-vraisemblance de l'échantillon $(x_1, \ldots, x_n)$ sous ce modèle.

Solution : La fonction de répartition $F_{\alpha,u}$ est continue sur $\mathbb{R}$ et dérivable sur $\mathbb{R}\backslash\{u\}$, c'est-à-dire presque partout. En la dérivant par morceaux sur $]-\infty, u[$ puis $]u, +\infty[$ (on peut choisir une

valeur positive arbitraire en u) on obtient pour densité de la loi de Pareto de paramètres $\alpha,u>0$ la fonction

$$\forall\, x\in\mathbb{R}\qquad f_{\alpha,u}(x)=\frac{\alpha\, u^{\alpha}}{x^{\alpha+1}}\mathbf{1}_{[u,+\infty[}(x).$$

Comme les variables sont supposées iid de même loi de densité $f_{\alpha,u}$, on a

$$L(x_1,\dots,x_n;\alpha,u)=\prod_{i=1}^{n}f_{\alpha,u}(x_i)=\left|\begin{array}{ll}\dfrac{\alpha^n u^{n\alpha}}{\left(\prod_{i=1}^n x_i\right)^{\alpha+1}} & \text{si } u\le\min\limits_{1\le i\le n}x_i,\\[2ex] 0 & \text{sinon.}\end{array}\right.$$

On en déduit la log-vraisemblance, définie pour $u\le\min\limits_{1\le i\le n}x_i$:

$$\ell(x_1,\dots,x_n;\alpha,u)=n\ln(\alpha)+n\alpha\ln(u)-(\alpha+1)\sum_{i=1}^{n}\ln(x_i).$$

***cf.* poly :** §3.5 §3.7.5 PC1

8. (3 points) Calculer l'estimation par maximum de vraisemblance du vecteur (α,u).

Solution : Tout d'abord, la vraisemblance est à valeurs dans $\mathbb{R}_+$, non-nulle pour $u\le\min\limits_{1\le i\le n}x_i$.

Pour tout $\alpha>0$ fixé, elle est croissante avec u entre 0 et $\min\limits_{1\le i\le n}x_i$, elle atteint donc son maximum en $\hat{u}=\min\limits_{1\le i\le n}x_i$ et on a

$$\forall\,\alpha,u>0\qquad L(x_1,\dots,x_n;\alpha,u)\le L(x_1,\dots,x_n;\alpha,\hat{u}).$$

Ainsi, pour trouver un maximum global de la vraisemblance, il ne reste qu'à maximiser la fonction $\alpha>0\mapsto L(x_1,\dots,x_n;\alpha,\hat{u})$ ou, de manière équivalente, son logarithme. Or, la log-vraisemblance prise en $\hat{u}$ est une fonction continue de α sur $\mathbb{R}_+^*$, concave comme somme de fonctions concaves. Elle est dérivable sur ce même ensemble, et atteint donc son maximum, s'il existe, là où sa dérivée s'annule. Cette dernière vaut pour tout $\alpha>0$:

$$\frac{\partial\ell}{\partial\alpha}(x_1,\dots,x_n;\alpha,\hat{u})=\frac{n}{\alpha}+n\ln(\hat{u})-\sum_{i=1}^{n}\ln(x_i)=\frac{n}{\alpha}-\sum_{i=1}^{n}\ln\left(\frac{x_i}{\hat{u}}\right).$$

Elle s'annule en $\hat{\alpha}=\dfrac{n}{\sum\limits_{i=1}^{n}\ln\left(\frac{x_i}{\hat{u}}\right)}$. On en conclut que la vraisemblance admet un maximum global, atteint en $(\hat{\alpha},\hat{u})$.

***cf.* poly :** §3.5 §3.7.5 PC1

9. (1 point) En déduire un estimateur de p_s pour s quelconque.

Solution : Notons $\hat{U} = \min_{1\leq i\leq n} X_i$ et $\hat{A} = \dfrac{n}{\sum_{i=1}^{n} \ln\left(\dfrac{X_i}{\hat{U}}\right)}$. En repartant de l'expression de la fonction de répartition de la loi de Pareto, on peut prendre pour estimateur de p_s la fonction de l'échantillon *aléatoire* suivante :

$$\hat{P}_s = 1 - F_{\hat{U},\hat{A}}(s) = \left(\frac{\hat{U}}{s}\right)^{\hat{A}}.$$

***cf.* poly :** §3.2.1

10. (2 points) La concentration maximale autorisée est de 1mg/kg. On observe 37 mesures la dépassant, et par maximum de vraisemblance on obtient l'estimation $\hat{\alpha} = 0{,}2$. Calculer et comparer les deux estimations considérées de la probabilité de dépasser ce seuil légal (on pourra se référer au tableau 1).

Solution : L'estimation par moyenne empirique et sans hypothèse sur la forme de la loi $\mathbb{P}_X$ donne $\hat{p}_1 = 0{,}185$. Celle par maximum de vraisemblance sous le modèle de Pareto étudié donne quant à elle $\hat{p}_1 \approx 0{,}251$. La seconde méthode donne un résultat bien plus élevé, conservateur, que la première ; elle est adaptée à l'étude des distributions à queues lourdes.

***cf.* poly :** §3.1.2 §3.2.1

		b				
		0,1	0,2	0,3	0,4	0,5
	0,1	0,794	0,631	0,501	0,398	0,316
	0,01	0,631	0,398	0,251	0,158	0,100
a	0,001	0,501	0,251	0,126	0,063	0,032
	0,0001	0,398	0,158	0,063	0,025	0,010
	0,00001	0,316	0,100	0,032	0,010	0,003

TABLEAU 1 – Table de valeurs de a^b arrondies à trois chiffres après la virgule.

Exercice 2 : Réflexe de fermeture des *Mytilus*

Les *Mytilus* sont des mollusques bivalves. Lorsqu'ils sont soumis à des stimuli soudains de prédation, les *Mytilus* ont un réflexe de fermeture rapide de leurs deux valves qui permet de protéger leur corps mou. Ils se rouvrent une fois le danger passé, et peuvent alors respirer et se nourrir. Une publication récente[1] étudie l'influence potentielle d'un changement d'environnement causé par le réchauffement climatique sur le temps d'ouverture des *Mytilus* après avoir été soumis à un stress prédateur.

Pour cela, les scientifiques ont collecté 120 de ces mollusques dans le fjord Gullmar sur la côte ouest suédoise. Ils les ont ensuite mesurés et pesés, afin de former deux groupes selon la longueur de la coquille : les *grands* de plus de 59mm, et les *petits* de moins de 58mm. Quatre scénarios ont été considérés, en combinant les pH et température suivants :

- un *pH ambiant* d'environ 8,17 contre un *pH faible* d'envrion 7,49 ;
- une *température élevée* d'environ 19,3°C contre une *température faible* d'environ 15,1°C.

Le temps d'ouverture de chacun des mollusques suite à sa fermeture, déclenchée par un contact, a ensuite été chronométré.

Les scientifiques ont ensuite modélisé la relation entre le temps d'ouverture, modélisé par une variable aléatoire Y, et les trois variables binaires (catégorie de taille, catégorie de pH et catégorie de température), modélisées par un vecteur aléatoire X, de la façon suivante :

$$\mathbb{E}(Y \mid X) = g\left(X\vec{\beta}\right),$$

ou $\vec{\beta} \in \mathbb{R}^3$ décrit la contribution de chacune des variables au modèle et $g : \mathbb{R} \to [0,1]$ est une fonction fixée.

Les données récoltées leur ont permis d'estimer la valeur de $\vec{\beta}$.

Un test statistique leur a ensuite permis de tester, pour chacune des trois variables, si elle contribue ou non au modèle.

La figure 2, tirée de l'article, résume les résultats.

11. (1 point) Quelle est l'hypothèse nulle du test statistique pour la variable j ($j \in \{1,2,3\}$) ?

Solution : La variable j n'a pas d'effet sur le temps d'ouverture, soit $\beta_j = 0$.

***cf.* poly :** §4.2.1

12. (1 point) Quelle est l'hypothèse alternative ? S'agit-il d'un test uni- ou bi-latéral (justifier) ?

Solution : L'hypothèse alternative est que la variable j a un effet sur le temps d'ouverture, soit $\beta_j \neq 0$. Il s'agit d'un test bilatéral, car nous ne savons pas si nous devons nous attendre à une augmentation ou une diminution du temps d'ouverture.

***cf.* poly :** §4.2.1 §4.2.4

13. (1 point) Comment interpréter la figure 2 ?

Solution : D'après le tableau, la taille et la température ont une influence sur le temps d'ouverture des *Mytilus* (p-valeur infime), mais pas le pH (p-valeur trop grande pour pouvoir rejeter l'hypothèse nulle). Les boîtes à moustaches permettent de voir que le temps d'ouverture est d'une part globalement plus faible pour les grands *Mytilus* que les petits, et d'autre part globalement plus élevé sous haute température qu'en milieu plus froid.

***cf.* poly :** §2.2 §4.2.5

Source of error	*df*	model	
		χ^2	*P*
Size class	1	**34.56**	**<0.0001**
pH_T	1	1.30	0.2540
Temp.	1	**20.52**	**<0.0001**

Bolded text denotes significant effects.

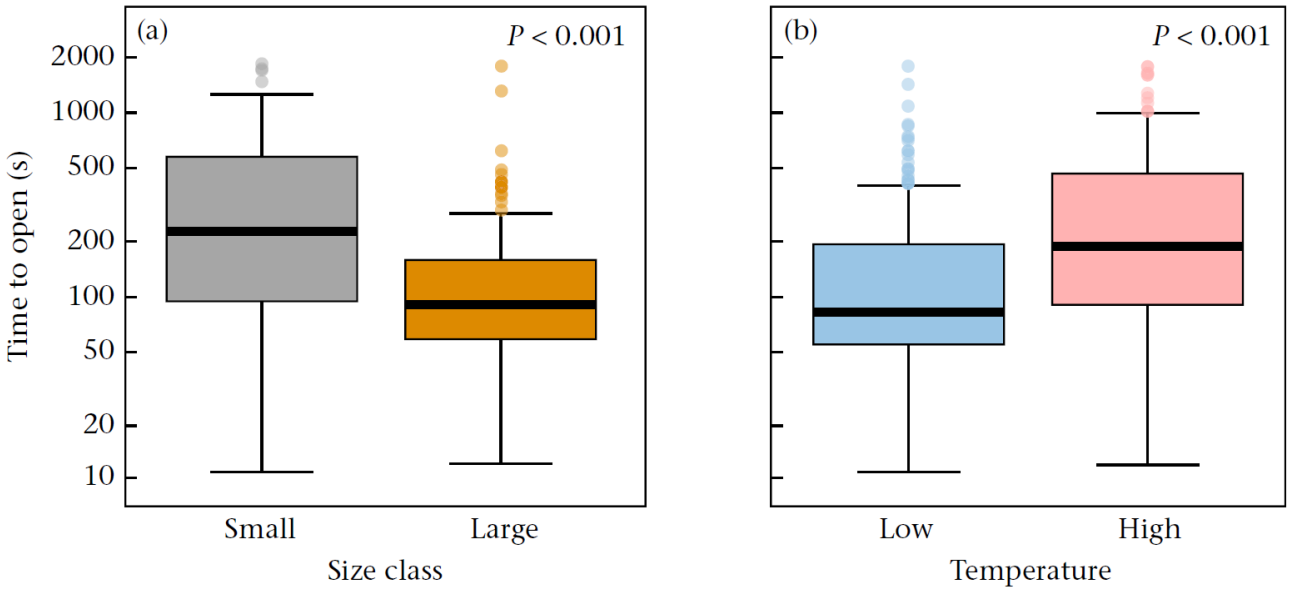


FIGURE 2 – **En haut** - Tableau de résultats du test statistique pour chacune des trois variables considérées. **En bas** - Boîtes à moustaches du temps d'ouverture selon les différents groupes d'individus : en fonction de leur taille (à gauche) et de la température (à droite). Les p-valeurs indiquées sont celles du test statistique pour la variable considérée.

1. https://doi.org/10.1016/j.anbehav.2020.12.008

Partie 2

À rendre sur une copie différente de la partie 1.

Exercice 3 : Décrochage scolaire

On souhaite construire un modèle prédisant le taux d'abandon scolaire au lycée (c'est-à-dire la proportion d'élèves quittant le système scolaire avant l'obtention du baccalauréat), à partir de variables socio-économiques décrivant l'ensemble des familles des élèves (par exemple : revenus moyens ; taux d'emploi) ou l'établissement (par exemple : proportion de non-remplacement en cas d'absence des enseignantes ou enseignants).

Pour cela, on collecte un jeu de données $\mathcal{D} = \{(\vec{x}^{\,1},y^1),\dots,(\vec{x}^{\,n},y^n)\}$ contenant $n = 300$ observations, chacune correspondant à un lycée décrit par $p = 20$ variables réelles et une étiquette, elle aussi réelle.

14. (1 point) Quel peut être l'intérêt de disposer d'un tel modèle ? (1-5 lignes)

Solution : Comprendre l'impact potentiel d'inégalités socios-économiques, notamment en interprétant les modèles.

15. (1 point) Au contraire, comment un tel modèle pourrait-il être mal utilisé ? (1-5 lignes)

Solution : Création d'un « score » quantifiant « objectivement » si un lycée est « bon » ou « mauvais », utilisé à mauvais escient par les familles (refusant d'inscrire leurs enfants dans un établissement « mauvais » ou les pouvoirs politiques (qui pourraient refuser de donner plus de moyens à de « mauvais » établissements.) Utilisation du modèle pour faire des prédictions au niveau d'un élève, puis discrimination sur cette base.

16. (1 point) À quoi prêter attention pendant la collecte des données pour ce projet ? (1-5 lignes)

Solution : Les données ne sont pas personnelles/identifiantes puisqu'elles concernent tout un établissement. Attention à la représentativité des lycées choisis, et à la pertinence et la qualité (les établissements peuvent-ils mentir ?) des variables mesurées.

On considère tout d'abord un algorithme d'apprentissage supervisé, que l'on appellera ALGO, qui résout le problème de minimisation du risque empirique suivant, avec $\eta \geq 0$:

$$\min_{a\in\mathbb{R},\vec{\alpha}\in\mathbb{R}^p,B\in\mathbb{R}^{p\times p},\vec{\gamma}\in\mathbb{R}^p} \frac{1}{n}\sum_{i=1}^{n}\left(a + \sum_{j=1}^{p}\left(\alpha_j x_j^i + \left(\sum_{k=1}^{p} B_{jk}\, x_j^i x_k^i\right) + \gamma_j (x_j^i)^3\right) - y^i\right)^2 + \eta\left(a^2 + \sum_{j=1}^{p}\left(\alpha_j^2 + \gamma_j^2 + \sum_{k=1}^{p} B_{jk}^2\right)\right). \tag{1}$$

17. (1 point) Quel est l'espace des hypothèses d'ALGO ?

Solution :

$$\left\{x \mapsto a + \sum_{j=1}^{p}\left(\alpha_j x_j + \sum_{k=1}^{p}\left(B_{jk}\, x_j x_k\right) + \gamma_j x_j^3\right); a \in \mathbb{R}, \vec{\alpha} \in \mathbb{R}^p, B \in \mathbb{R}^{p\times p}, \vec{\gamma} \in \mathbb{R}^p\right\}.$$

18. (1 point) Quelle est la fonction de perte (aussi appelée fonction de coût, ou fonction d'erreur) utilisée dans l'équation 1 ?

Solution : La perte quadratique.

19. (1 point) Combien de paramètres ALGO apprend-il ?

Solution : 1 (a) + 20 ($\vec{\alpha}$) + 20 $\times$20 (B) + 20 ($\vec{\gamma}$) = 441.

20. (1 point) À quoi sert le terme pondéré par η dans l'équation (1) ?

Solution : Terme de régularisation (ℓ_2), contraint les coefficients du modèle, sert à éviter le surapprentissage.

21. (2 points) Que se passe-t-il quand $\eta \to 0$? Quand $\eta \to +\infty$?

Solution : Quand $\eta \to 0$: Pas de régularisation, on résout un simple problème de minimisation du risque empirique, risque de surapprentissage.
Quand $\eta \to +\infty$: on ignore l'erreur, tous les coefficients tombent à 0, on n'apprend plus.

22. (1 point) Comment résoudre le problème d'optimisation donné par l'équation (1) en utilisant un

algorithme fait pour apprendre des régressions linéaires ridge ?

Solution : Transformer $\vec{x} \in \mathbb{R}^p$ en un vecteur de dimension 441 dont les composantes sont

$$(1, x_1, x_2, \ldots, x_p, x_1^2, x_1 x_2, \ldots x_p^2, x_1^3, x_2^3, \ldots, x_3^3)$$

puis apprendre une régression linéaire ridge sur ces variables.

23. (1 point) Comment déterminer la valeur de η ? (1-2 lignes)

Solution : Recherche par grille (échelle logarithmique) + validation croisée.

On considère maintenant un perceptron multi-couche prenant en entrée les p variables et ayant les caractéristiques suivantes :

- 2 couches intermédiaires (aussi appelées couches cachées), de tailles (c'est-à-dire le nombre de neurones qu'elles contiennent) respectivement h_1 et h_2 ;
- pas d'unité de biais ;
- chaque neurone a la même fonction d'activation φ, sauf le neurone de sortie qui utilise une fonction d'activation linéaire. On considère que φ est fixée.

On appelle ce perceptron multi-couche « PMC ».

24. (1 point) Quel est l'espace des hypothèses que l'on considère avec PMC ?

Solution :

$$\left\{ x \mapsto \sum_{q=1}^{h_2} w_q^2 \varphi \left(\sum_{k=1}^{h_1} W_{kq}^1 \varphi \Big(\sum_{j=1}^{p} W_{jk}^0 x_j \Big) \right) ; W^0 \in \mathbb{R}^{p \times h_1}, W^1 \in \mathbb{R}^{h_1 \times h_2}, \vec{w}^{\,2} \in \mathbb{R}^{h_2} \right\}.$$

25. (1 point) Suggérer une valeur pour h_1 et une valeur pour h_2 permettant à PMC d'apprendre un modèle ayant à peu près le même nombre de paramètres qu'un modèle appris par ALGO (cf question 19).

Solution : Le nombre de paramètres du réseau de neurones est $p \times h_1$ (entrée $\to$ couche 1) + $h_1 \times h_2$ (couche 1 $\to$ couche 2) + h_2 (couche 2 $\to$ sortie) = $20h_1 + h_1 h_2 + h_2$. Exemples de solutions possibles :

- $h_1 = 20$ et $h_2 = 2$: $400 + 40 + 2 = 442$ paramètres
- $h_1 = 10$ et $h_2 = 20$: $200 + 200 + 20 = 420$ paramètres
- $h_1 = 10$ et $h_2 = 21$: $200 + 210 + 21 = 431$ paramètres.

26. (2 points) Le problème d'optimisation décrit par l'équation (1) et le problème d'optimisation correspondant à apprendre les paramètres de PMC admettent-ils une solution unique ? Quelles en sont les conséquences pour l'apprentissage ?

Solution : ALGO : Problème convexe, unicité de la solution ; PMC : problème non-convexe, risque de tomber dans un minimum local. On utilise la méthode du gradient dans les deux cas, mais pour PMC on risque de ne pas atteindre le minimum global : si les perfs sont mauvaises, on ne sait pas si c'est l'espace des hypothèses qui ne convient pas ou l'optimisation qui n'a pas fonctionné.

La figure 3 représente la RMSE de modèles appris avec ALGO et de modèles appris avec PMC. Plus précisément, les deux algorithmes sont comparés dans le cadre d'une validation croisée, et la figure présente la RMSE sur le jeu d'entraînement et sur le jeu de validation de chacun des folds ; les barres d'erreur représentent la variabilité (un écart-type) de cette RMSE entre les folds.

27. (1 point) Lequel de ces deux algorithmes choisir pour entraîner un modèle sur l'ensemble des données disponibles et pourquoi ?

Solution : ALGO, car il a une plus petite RMSE en validation. PMC sur-apprend.

28. (1 point) Comment pourrait-on modifier la mise en forme de la figure 3 pour en améliorer la lisibilité ?

Solution : L'échelle de l'axe vertical écrase les barres représentées.

29. (1 point) Les RMSE des modèles obtenues sur la figure 3 vous semblent-elles suffisamment bonnes pour l'application envisagée en réponse à la question 14 ?

Solution : Erreur moyenne supérieure à 10% : c'est beaucoup pour un taux qui doit être en moyenne inférieur à cette valeur. Le modèle va être difficile à utiliser.
Remarques :

- la RMSE n'est pas un pourcentage d'erreur !
- on fait des prédictions pour des *lycées*, pas des *élèves*

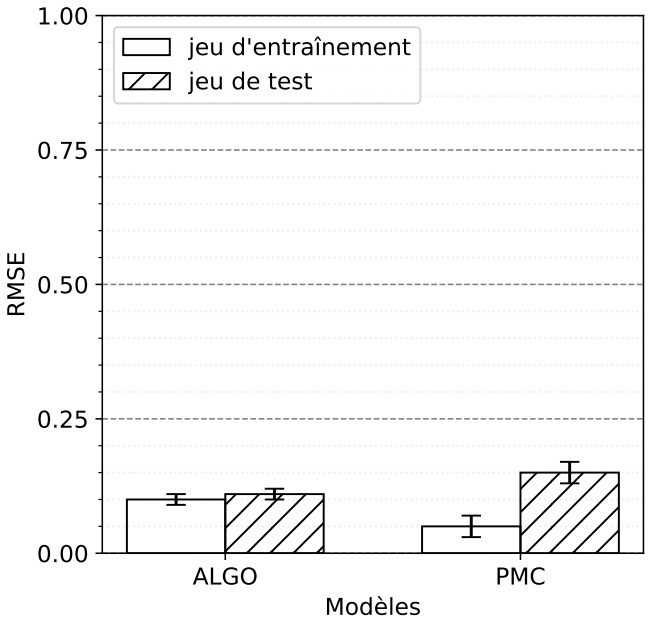


FIGURE 3 – Comparaison des performances des deux algorithmes d'apprentissage.

FIN DU SUJET