

1 Estimateur du nombre de boules dans une urne

On considère une urne contenant n boules, numérotées de 1 à n . On ne connaît pas n et on souhaite l'estimer. Pour cela, on procède à m tirages avec remise.

1. Donner un estimateur simple de n .
2. Calculer l'estimateur par maximum de vraisemblance de n .
3. Montrer que le biais de cet estimateur est

$$-\sum_{k=1}^{n-1} \left(\frac{k}{n}\right)^m.$$

Que vaut-il quand $m = 1$? Quand $m \rightarrow +\infty$?

Solution

Modélisation : Échantillon aléatoire (X_1, X_2, \dots, X_m) où X_i est le numéro de la boule tirée au i -ème tirage.

La loi de X est donnée par :

$$\mathbb{P}_X(X = k|n) = \begin{cases} \frac{1}{n} & \text{si } k \in [1, \dots, n] \\ 0 & \text{sinon} \end{cases} = \frac{1}{n} 1_{[1, \dots, n]}(k).$$

Question 1. Un estimateur naturel de n est

$$N_m = \max_{i=1, \dots, m} (X_i).$$

Une autre possibilité est d'observer que X étant uniforme sur $[1, n]$, la moyenne empirique des X_i s'approche de $\frac{n+1}{2}$, et de suggérer

$$N_m = 2 \frac{1}{m} \sum_{i=1}^m X_i - 1.$$

Question 2. La vraisemblance d'un échantillon (x_1, x_2, \dots, x_m) pour l'estimation η de n vaut

$$L(x_1, x_2, \dots, x_m | \eta) = \prod_{i=1}^m \frac{1}{\eta} 1_{[1, \dots, \eta]}(x_i).$$

L'estimation par maximum de vraisemblance de n est donc

$$\hat{n}_{\text{MLE}} = \arg \max_{\eta \in \mathbb{N}^*} \prod_{i=1}^m \frac{1}{\eta} 1_{[1, \dots, \eta]}(x_i).$$

La quantité $\prod_{i=1}^m \frac{1}{\eta} 1_{[1, \dots, \eta]}(x_i)$ est positive, et non nulle dès que toutes les indicatrices valent 1, c'est-à-dire que $x_i \leq \eta$ pour tout $i = 1, \dots, m$. Enfin, quand elle est non-nulle, elle est d'autant plus petite que η est grand. Ainsi \hat{n}_{MLE} doit être aussi petit que possible tout en majorant tous les x_i . On a donc

$$\hat{n}_{\text{MLE}} = \max_{i=1, \dots, m} (x_i),$$

et l'estimateur par maximum de vraisemblance de n est la variable aléatoire réelle

$$\hat{N}_{\text{MLE}} = \max_{i=1, \dots, m} (X_i).$$

Le premier des estimateurs que nous avons proposé à la question précédente est en fait l'estimateur par maximum de vraisemblance de N .

Question 3. Le biais de l'estimateur que nous avons proposé est, par définition :

$$B(N_m) = \mathbb{E}(N_m) - n.$$

Calculons $\mathbb{E}(N_m)$:

$$\begin{aligned} \mathbb{E}(N_m) &= \sum_{k=1}^n k \mathbb{P}(N_m = k) \text{ par définition} \\ &= \sum_{k=1}^n \mathbb{P}(N_m \geq k) \\ &= \sum_{k=1}^n 1 - \mathbb{P}(N_m \leq (k-1)) \\ &= n - \sum_{k=1}^n \left(\frac{(k-1)}{n} \right)^m \\ &= n - \sum_{k=1}^{n-1} \left(\frac{k}{n} \right)^m. \end{aligned}$$

La deuxième ligne s'obtient en observant que

$$\begin{aligned} \sum_{k=1}^n \mathbb{P}(N_m \geq k) &= \mathbb{P}(N_m \geq n) + \mathbb{P}(N_m \geq n-1) + \dots + \mathbb{P}(N_m \geq 1) \\ &= \mathbb{P}(N_m = n) + (\mathbb{P}(N_m = n) + \mathbb{P}(N_m = n-1)) + \dots + \\ &\quad (\mathbb{P}(N_m = n) + \mathbb{P}(N_m = n-1) + \dots + \mathbb{P}(N_m = 1)), \end{aligned}$$

puis en regroupant ensemble les n termes $\mathbb{P}(N_m = n)$, les $(n-1)$ termes $\mathbb{P}(N_m = n-1)$, etc.

La quatrième ligne s'obtient en observant que l'événement " $N_m \leq k-1$ " est équivalent à l'événement " $X_i \leq k-1$ pour $i = 1, \dots, m$ ", que $\mathbb{P}(X_i \leq k-1) = \frac{k-1}{n}$, et que les X_i sont indépendants.

Ainsi notre estimateur est biaisé, et son biais vaut

$$B(N_m) = - \sum_{k=1}^{n-1} \left(\frac{k}{n} \right)^m.$$

Ce biais est négatif : la valeur estimée est en moyenne plus faible que le nombre de boules. Il est peu probable de tirer la boule numéro n , sauf à faire un très grand nombre de tirages.

Tirer une seule boule ($m = 1$) est équivalent à tirer une valeur uniformément entre 1 et n , on s'attend donc à être plus proche de $\frac{n+1}{2}$ (espérance d'une variable aléatoire réelle uniformément distribuée sur $[1, n]$) que de n . On a bien

$$B(N_1) = - \sum_{k=1}^{n-1} \left(\frac{k}{n} \right) = - \frac{1}{n} \frac{n(n-1)}{2} = - \frac{n-1}{2} = \frac{n+1}{2} - n.$$

Par ailleurs, le biais tend vers 0 quand $m \rightarrow +\infty$. N_m est asymptotiquement non biaisé.

2 Estimation de densité

Considérons une variable aléatoire X suivant une loi normale de paramètres μ et σ^2 .

1. Étant donné un échantillon de $n \in \mathbb{N}^*$ observations de X , calculer l'estimateur par maximum de vraisemblance de μ et σ .
2. Supposons maintenant que μ est la réalisation d'un variable aléatoire réelle M qui suit une loi normale de moyenne m et de variance τ^2 . Calculer l'estimateur de Bayes de μ .
3. Décomposer l'estimateur de Bayes de μ en la somme d'un terme fonction de la moyenne empirique de l'échantillon et un terme dépendant de la moyenne a priori. Que se passe-t-il quand n augmente ?

Solution

Question 1 Appelons (x_1, x_2, \dots, x_n) notre échantillon. Il s'agit d'une réalisation de l'échantillon aléatoire (X_1, X_2, \dots, X_n) composé de variables i.i.d. de même loi que X . La vraisemblance de cet échantillon est

$$L(x_1, x_2, \dots, x_n; \mu, \sigma) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right),$$

et sa log-vraisemblance est donc

$$\ell(x_1, x_2, \dots, x_n; \mu, \sigma) = \sum_{i=1}^n -\ln(\sigma\sqrt{2\pi}) - \frac{(x_i - \mu)^2}{2\sigma^2}.$$

Nous cherchons

$$\hat{\mu}_{\text{MLE}}, \hat{\sigma}_{\text{MLE}} \in \arg \max_{\hat{\mu}, \hat{\sigma} \in \mathbb{R}^2} \ell(x_1, x_2, \dots, x_n; \hat{\mu}, \hat{\sigma}).$$

La fonction $\mu \mapsto \sum_{i=1}^n -\ln(\sigma\sqrt{2\pi}) - \frac{(x_i - \mu)^2}{2\sigma^2}$ est une fonction concave, dont le gradient en μ vaut $\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} (n\mu - \sum_{i=1}^n x_i)$. En annulant ce gradient, on obtient $\hat{\mu}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n x_i$. L'estimateur par maximum de vraisemblance de l'espérance de X est sa moyenne empirique.

En remplaçant μ par $\hat{\mu}_{\text{MLE}}$ et en appelant $\alpha = \frac{1}{\sigma^2}$, la fonction $\alpha \mapsto \frac{1}{2} \sum_{i=1}^n -\ln(2\pi) + \ln(\alpha) - (x_i - \mu)^2 \alpha$ est concave (sa dérivée seconde est proportionnelle à $-\frac{1}{\alpha^2} < 0$). En annulant son gradient, on obtient $\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu}_{\text{MLE}})^2$ et $\hat{\sigma}_{\text{MLE}}$ est donc l'écart-type empirique.

Question 2 Nous supposons maintenant que μ est la réalisation d'une variable aléatoire réelle $M \sim \mathcal{N}(m, \tau^2)$. Son estimateur de Bayes est $\hat{\mu}_{\text{Bayes}} = \mathbb{E}(M|X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$.

Pour déterminer cette espérance, calculons la densité correspondante :

$$\begin{aligned} \mathbb{P}(M = \mu|X_1, X_2, \dots, X_n) &= \frac{\mathbb{P}(X_1, X_2, \dots, X_n|M = \mu)\mathbb{P}(M = \mu)}{\mathbb{P}(X_1, X_2, \dots, X_n)} \text{ (Bayes)} \\ &= \frac{1}{\mathbb{P}(X_1, X_2, \dots, X_n)} \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \exp \left(- \sum_{i=1}^n \frac{(X_i - \mu)^2}{2\sigma^2} \right) \frac{1}{\tau\sqrt{2\pi}} \exp \left(- \frac{(\mu - m)^2}{2\tau^2} \right) \\ &= \mathcal{K}_1 \exp \left(- \sum_{i=1}^n \frac{(X_i - \mu)^2}{2\sigma^2} - \frac{(\mu - m)^2}{2\tau^2} \right) \text{ où } \mathcal{K}_1 \text{ ne dépend pas de } \mu. \end{aligned}$$

Ainsi,

$$\begin{aligned} \mathbb{P}(M = \mu|X_1, X_2, \dots, X_n) &= \mathcal{K}_1 \exp \left(- \frac{1}{2} \left[\frac{1}{\sigma^2} \sum_{i=1}^n (X_i^2 + \mu^2 - 2X_i\mu) + \frac{1}{\tau^2} (\mu^2 + m^2 - 2\mu m) \right] \right) \\ &= \mathcal{K}_1 \exp \left(- \frac{1}{2} \left[\left(\frac{n}{\sigma^2} + \frac{1}{\tau^2} \right) \mu^2 - 2 \left(\frac{\sum_{i=1}^n X_i}{\sigma^2} + \frac{m}{\tau^2} \right) \mu + \frac{\sum_{i=1}^n X_i^2}{\sigma^2} + \frac{m^2}{\tau^2} \right] \right) \\ &= \mathcal{K}_1 \exp \left(- \frac{1}{2} \frac{(\mu - a)^2}{b^2} \right) \exp \left(- \frac{1}{2} \mathcal{K}_2 \right), \end{aligned}$$

où \mathcal{K}_1 et \mathcal{K}_2 ne dépendent pas de μ ,

$$a = \frac{\sum_{i=1}^n X_i \tau^2 + m \sigma^2}{n \tau^2 + \sigma^2} \text{ et } b = \sqrt{\frac{\tau^2 \sigma^2}{n \tau^2 + \sigma^2}}.$$

L'intégrale d'une densité de probabilité vaut 1. Cela vaut pour la loi normale centrée en a et d'écart-type b , comme pour $\mathbb{P}(M|X_1, X_2, \dots, X_n)$, et donc $\mathcal{K}_1 \exp \left(- \frac{1}{2} \mathcal{K}_2 \right) = \frac{1}{b\sqrt{2\pi}}$.


Ainsi, $M|X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ suit une loi normale centrée en a . Son espérance vaut donc a , et ainsi

$$\hat{\mu}_{\text{Bayes}} = \frac{\sum_{i=1}^n x_i \tau^2 + m \sigma^2}{n \tau^2 + \sigma^2}.$$

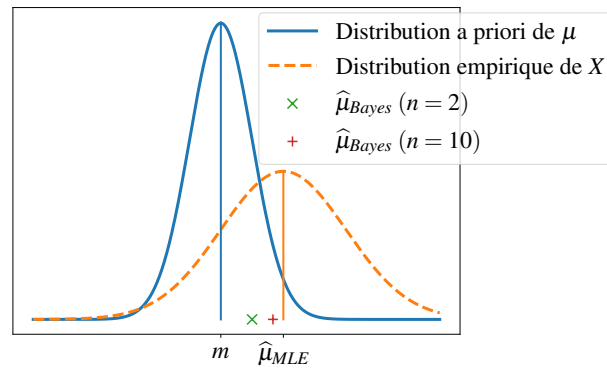
Question 3

$$\hat{\mu}_{\text{Bayes}} = \frac{n/\sigma^2}{n/\sigma^2 + 1/\tau^2} \hat{\mu}_{\text{MLE}} + \frac{1/\tau^2}{n/\sigma^2 + 1/\tau^2} m.$$

Plus il y a de données et plus l'estimateur de Bayes est proche de la moyenne empirique. Quand il y a peu de données, l'estimateur de Bayes est plus proche de la valeur a priori du paramètre. Ce phénomène est illustré sur la figure 1.



(A) Estimation de Bayes en fonction de la taille de l'échantillon.



(B) Distribution empirique de X et distribution a priori de μ .

FIGURE 1 – Estimation de Bayes de la moyenne d'une gaussienne. Ici $\hat{\mu}_{MLE}^2 = 2$ et $\hat{\sigma}_{MLE}^2 = 2$, tandis que $m = 0$ et $\tau^2 = 1$. Plus n est grand, plus on s'éloigne de la valeur a priori de μ pour se rapprocher de son estimation empirique.